PULSO

ENTREGA 1 / E4

Modelo de datos

Proyecto Final Backend · 13 de noviembre de 2026

Miguel Ángel Márquez Coronel · María Gabriela Rey Barrios · Andrés Felipe Serrano Mendoza

6. E4. Modelo de datos

6.1. Descripción general

El modelo de datos de PULSO responde a las necesidades de almacenamiento y recuperación de información relacionadas con las funcionalidades de predicción cardiovascular, explicabilidad, simulación y generación de recomendaciones educativas.

La arquitectura distingue dos almacenamientos persistentes con finalidades diferentes —PostgreSQL local para usuarios e historiales y Supabase/pgvector para el corpus del RAG—, además de la memoria del backend utilizada para conservar temporalmente contextos de análisis.

El registro, la autenticación y la consulta de historiales forman parte de las funcionalidades implementadas. La persistencia específica de roles, consentimientos, sesiones y simulaciones no está acreditada como parte del esquema relacional actual.

Por tanto, el modelo se organiza en tres categorías:

1. **Persistencia documental del sistema RAG:** almacenamiento vectorial de fragmentos documentales y metadatos en Supabase, basado en PostgreSQL y pgvector.
2. **Almacenamiento temporal de análisis:** conservación transitoria de los datos y resultados necesarios para continuar las operaciones de la plataforma.
3. **Persistencia de usuarios e historiales:** tablas relacionales users y analyses, creadas mediante migraciones SQL versionadas.

Esta separación permite representar los almacenamientos existentes sin confundir los datos persistentes de cuentas y resultados con los documentos educativos de la base vectorial.

6.2. Persistencia documental del sistema RAG

PULSO utiliza Supabase, basado en PostgreSQL y la extensión pgvector, como infraestructura de almacenamiento y recuperación semántica para el corpus documental del sistema RAG.

Durante la reconstrucción del corpus se creó public.documents_pulso_test como tabla aislada para verificaciones. Esa misma tabla fue adoptada posteriormente por el RAG productivo, conservando su nombre. La tabla anterior public.documents se distingue de la colección normalizada.

6.2.1. Estructura de almacenamiento

La tabla public.documents_pulso_test contiene los siguientes campos:

Columna	Tipo	Descripción
id	BIGINT	Identificador del fragmento almacenado
content	TEXT	Contenido textual del fragmento
metadata	JSONB	Información bibliográfica, documental y estructural
embedding	VECTOR(3072)	Representación vectorial del contenido

El modelo utilizado para generar las representaciones vectoriales es models/gemini-embedding-001, con una dimensionalidad de 3072.

La información de los documentos se organiza mediante metadatos como document_id, source_file, source, source_url, author, chunk_index, section_path y chunking_version.

Estos metadatos permiten identificar la procedencia de los fragmentos y mantener su trazabilidad.

6.2.2. Preparación y fragmentación documental

El corpus se compone de 15 documentos seleccionados y normalizados, relacionados con factores cardiovasculares y recomendaciones educativas.

Los documentos se procesaron mediante una estrategia de fragmentación estructural basada en Markdown, identificada como markdown_structural_v1_3.

Esta estrategia busca conservar la coherencia de títulos, secciones y párrafos.

Se estableció un tamaño objetivo de 650 caracteres por fragmento y un umbral de advertencia de 1200 caracteres. El tamaño objetivo no constituye un límite estricto.

El proceso produjo 160 fragmentos documentales.

6.2.3. Vectorización e ingesta

La ingesta documental se realizó mediante un flujo de n8n que recupera los archivos normalizados, prepara los fragmentos y sus metadatos, genera embeddings mediante Google Gemini e inserta los registros en Supabase.

Los 160 fragmentos generaron embeddings de 3072 dimensiones y fueron almacenados en public.documents_pulso_test, tabla que actualmente utiliza el RAG operativo en producción.

Las auditorías estructurales reportadas confirmaron:

- 15 documentos distintos.
- 160 registros almacenados.
- 160 embeddings no nulos con dimensionalidad correcta.
- Ausencia de contenido vacío.
- Ausencia de faltantes en los metadatos obligatorios evaluados.
- Secuencias de fragmentos completas y sin duplicaciones de índices por documento.

6.2.4. Recuperación semántica

La recuperación documental se realiza mediante la función public.match_documents_pulso_test, que permite efectuar búsquedas por similitud coseno y aplicar filtros opcionales mediante metadatos JSONB.

Las pruebas documentadas incluyeron nueve consultas relacionadas con presión arterial, actividad física, tabaquismo, alcohol, envejecimiento y diferencias cardiovasculares asociadas con sexo y género.

Los resultados mostraron recuperación temática y trazabilidad documental en los casos evaluados.

Estas pruebas respaldan el funcionamiento básico del mecanismo de recuperación, pero no constituyen una validación clínica de las recomendaciones generadas ni una evaluación comparativa exhaustiva frente a versiones anteriores.

6.2.5. Estado de implementación y validación

El sistema RAG de PULSO utiliza actualmente en producción la tabla public.documents_pulso_test, alojada en Supabase mediante PostgreSQL y la extensión pgvector.

Esta tabla almacena el corpus documental normalizado, compuesto por 15 documentos y 160 fragmentos vectorizados mediante el modelo models/gemini-embedding-001, con representaciones de 3072 dimensiones.

La recuperación semántica se realiza mediante la función public.match_documents_pulso_test, que permite efectuar búsquedas por similitud coseno y aplicar filtros opcionales sobre los metadatos documentales.

La tabla fue creada originalmente para realizar pruebas de reconstrucción del corpus. Sin embargo, tras las verificaciones técnicas realizadas, fue adoptada como fuente documental de la versión productiva del sistema RAG, conservando su denominación original.

Las auditorías estructurales documentadas verificaron la integridad de los registros, la disponibilidad de los embeddings y la presencia de los metadatos obligatorios. Estas verificaciones respaldan la correcta ingesta del corpus, aunque no constituyen por sí solas una validación clínica de las recomendaciones generadas.

El almacenamiento vectorial se utiliza exclusivamente para organizar y recuperar contenido educativo. No constituye una base de datos de cuentas de usuarios ni un repositorio persistente de historiales personales.

6.3. Almacenamiento temporal de análisis

PULSO utiliza un mecanismo de almacenamiento temporal para conservar el contexto necesario durante determinadas operaciones.

El contexto agrupa:

- Perfil cardiovascular utilizado en la predicción.
- Probabilidad y clasificación obtenidas.
- Umbral y versión del modelo.
- Explicación de los factores mediante SHAP.

La finalidad de este mecanismo es permitir que el backend reutilice los resultados previamente calculados al solicitar información educativa mediante RAG.

De esta manera se evita ejecutar nuevamente la inferencia exclusivamente para generar recomendaciones.

Este almacenamiento temporal no equivale al historial persistente de resultados, que se conserva por separado en la tabla PostgreSQL analyses.

En consecuencia, no requiere representar cada contexto como una tabla relacional permanente dentro del modelo entidad-relación.

Su implementación actual utiliza memoria del proceso, por lo que la información está sujeta a las condiciones de expiración y disponibilidad establecidas por el repositorio temporal.

Este mecanismo tampoco debe presentarse como una solución de persistencia compartida entre múltiples instancias del backend.

6.4. Modelo relacional PostgreSQL implementado

El backend utiliza PostgreSQL 16 para conservar cuentas y resultados resumidos de análisis. El esquema está descrito mediante las migraciones 001_create_users.sql y 002_create_analysis_history.sql. Las tablas reales verificadas en esas migraciones son users y analyses.

6.4.1. Tabla users

Columna	Tipo PostgreSQL	Restricciones
id	UUID	PK
email	VARCHAR(254)	NOT NULL, UNIQUE
password_hash	VARCHAR(255)	NOT NULL

Columna	Tipo PostgreSQL	Restricciones
created_at	TIMESTAMPTZ	NOT NULL, DEFAULT CURRENT_TIMESTAMP

La contraseña se conserva como hash Argon2. El esquema implementado no incluye columnas name, is_active ni updated_at.

6.4.2. Tabla analyses

Columna	Tipo PostgreSQL	Restricciones
id	UUID	PK
user_id	UUID	NOT NULL, FK a users(id) con ON DELETE CASCADE
probability	DOUBLE PRECISION	NOT NULL, CHECK entre 0 y 1
classification	SMALLINT	NOT NULL, CHECK IN (0,1)
threshold	DOUBLE PRECISION	NOT NULL, CHECK entre 0 y 1
model_version	VARCHAR(50)	NOT NULL
created_at	TIMESTAMPTZ	NOT NULL, DEFAULT CURRENT_TIMESTAMP

Los resultados históricos no almacenan de forma persistente el perfil completo de entrada ni la explicación SHAP.

6.5. Relaciones, integridad e índices

La cardinalidad es **usuario 1:N análisis**: cada fila de analyses pertenece a un usuario, mientras que una cuenta puede tener cero o muchos resultados.

La clave foránea analyses.user_id referencia users.id y aplica ON DELETE CASCADE. La migración también crea el índice ix_analyses_user_created_at sobre (user_id, created_at DESC, id DESC), que facilita la consulta paginada del historial por cuenta y cronología.

La restricción UNIQUE sobre users.email impide registros duplicados. Las restricciones CHECK validan probabilidades, umbrales y clasificaciones a nivel de base de datos.

Para Supabase, los metadatos JSONB y los vectores de dimensión 3072 forman parte de la estructura documental; el informe de ingesta indica una restricción de unicidad propuesta para documento y fragmento, pero la relación exacta de índices físicos debe verificarse contra el catálogo SQL antes de declararla exhaustiva.

6.6. Tratamiento y minimización de datos personales

La plataforma procesa variables relacionadas con características físicas, presión arterial y hábitos personales. Para reducir la exposición, la persistencia relacional conserva el identificador de usuario, su correo electrónico, el hash de contraseña y resultados resumidos del análisis.

El contexto completo del perfil y la explicación se mantiene temporalmente en memoria para permitir el flujo educativo, sin formar parte de la tabla analyses. La colección Supabase almacena fragmentos educativos y metadatos bibliográficos, no historiales personales.

El diseño debe complementarse con información clara sobre el tratamiento de datos, controles de acceso, medidas de conservación y mecanismos de ejercicio de derechos conforme a las obligaciones aplicables, incluida la Ley 1581 de 2012. No se presume que existan flujos implementados de consentimiento específico o eliminación de cuenta cuando no están acreditados.

6.7. Delimitación de funcionalidades futuras

No se atribuyen al esquema implementado tablas como roles, user_roles, privacy_consents, auth_sessions o simulations. Pueden contemplarse en una evolución posterior, pero no deben presentarse como estructuras existentes ni incluirse en el diagrama ER implementado.

6.8. Figuras de las estructuras de datos

Las figuras presentan por separado la relación de cuentas e historiales de PostgreSQL y el almacenamiento documental de Supabase. Las dos imágenes fueron proporcionadas por el equipo y se insertan sin modificar su contenido.

Modelo entidad-relación PostgreSQL

PULSO — PostgreSQL 16 del backend (backend/migrations) · índice ix_analyses_user_created_at (user_id, created_at DESC, id DESC)

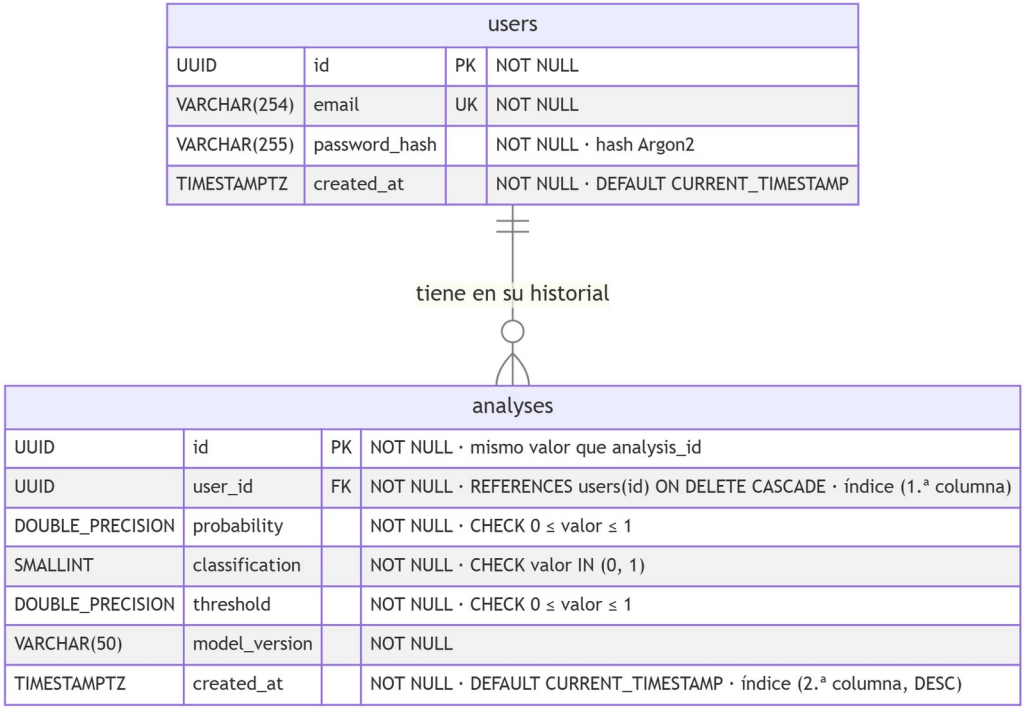


Figura 6.1 · Entidades y relaciones del historial persistente.

Esquema vectorial Supabase

Supabase — corpus vectorial del RAG, separado del PostgreSQL del backend (esquema informado por el equipo; no versionado en el repositorio)

documents_pulso_test			
BIGINT	id	PK	tabla public.documents_pulso_test
TEXT	content		texto del fragmento
JSONB	metadata		fuente y ubicación
VECTOR(3072)	embedding		gemini-embedding-001 · búsqueda con match_documents_pulso_test()

Figura 6.2 · Corpus RAG en Supabase.